Brecha digital y resultados Saber 11

¿El acceso a internet y computador en casa se refleja en el puntaje?

Proyecto final · Ciencia de Datos · Universidad EAN

Brandon Sayid Capacho Leal · Juan Nicolás Galindo

Ingeniería de Sistemas

La pregunta y los datos

Pregunta

¿Qué tanto se relaciona el acceso a internet y computador en el hogar con el puntaje global del Saber 11, y podemos predecir el desempeño con esa información?

¿Por qué nos importa como ingenieros de sistemas?

Diseñamos redes, plataformas y sistemas de información. Si la brecha digital se vuelve brecha de aprendizaje, los datos pueden guiar dónde invertir en tecnología.

Fuente

ICFES · Resultados únicos Saber 11 · datos.gov.co (API pública)

Muestra

Periodo 2022-2 · muestra sistemática por consecutivo (termina en 317, 569 u 842)

Tamaño

3.170 filas crudas → 1.584 estudiantes · 17 variables originales → 30 limpias

Herramientas

Python en Google Colab: pandas, seaborn, SciPy, statsmodels, scikit-learn

Exploración y limpieza

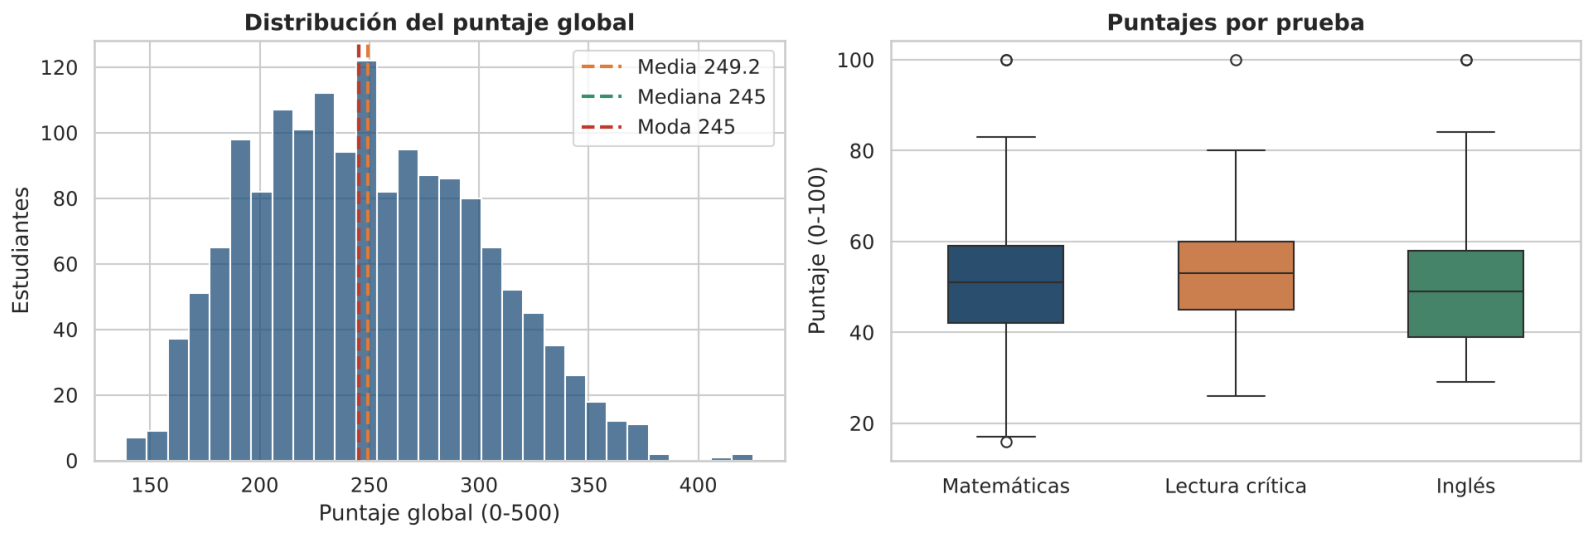
ETAPA 1

50 %	≈5 %	8	80
de las filas eran duplicadas	nulos en variables familiares	inglés = 0 (prueba no presentada)	validantes adultos (edad > 20)

Qué hicimos

- Eliminamos duplicados exactos y convertimos los puntajes de texto a número.
- Inglés = 0 y respuestas “No sabe / No aplica” → dato faltante.
- Fecha de nacimiento → edad; marcamos atípicos sin eliminarlos (jornada noche/sabatina).
- Normalizamos departamentos y los agrupamos en 5 regiones.
- Creamos variables nuevas: acceso digital (0-1-2), estrato agrupado, nivel educativo de la madre, banderas binarias.

¿Cómo se comportan los puntajes?



Puntaje global

Media 249 · Mediana 245 · Moda 245

Desv. estándar 50,7 · IQR 77 (210–287)

Distribución casi simétrica (asimetría 0,29)

Por prueba

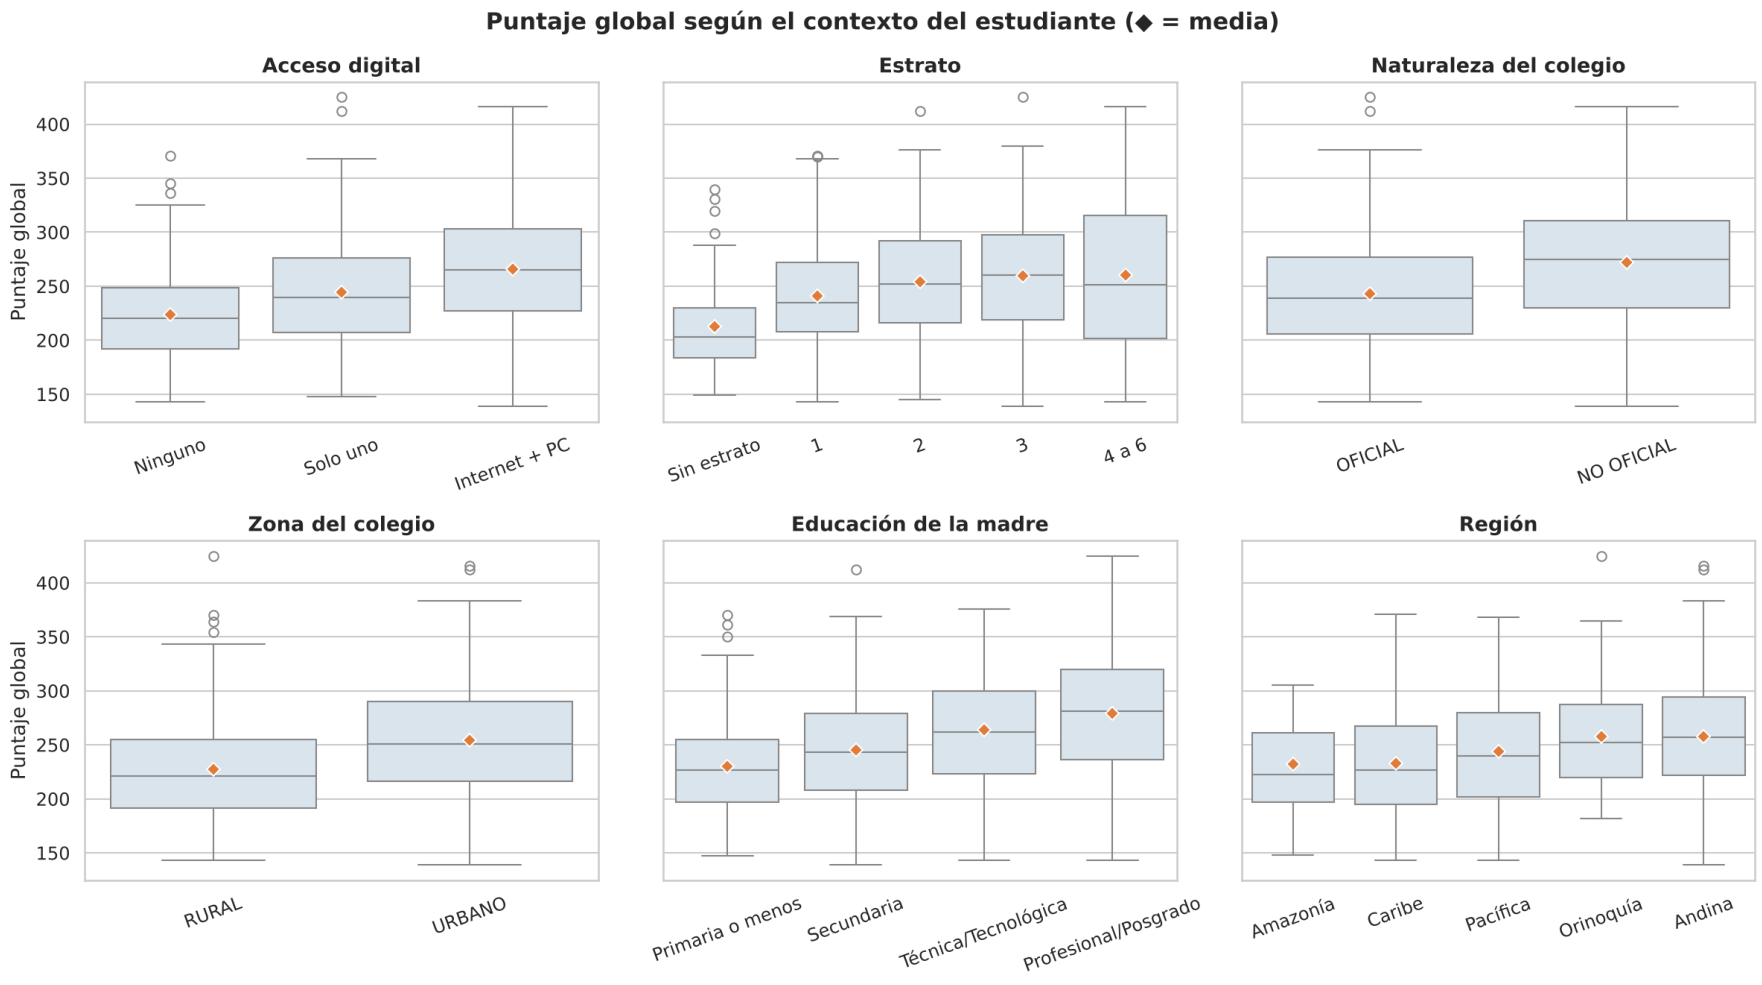
Lectura: la más alta y homogénea

Inglés y matemáticas: las más desiguales (CV 26 % y 24 %)

Atípicos

Solo 3 puntajes excepcionales (> 402): se conservan

El contexto marca diferencias



Diferencias de medias

Internet + PC vs. ninguno: +42

Internet: +33

Computador: +30

Colegio privado: +29

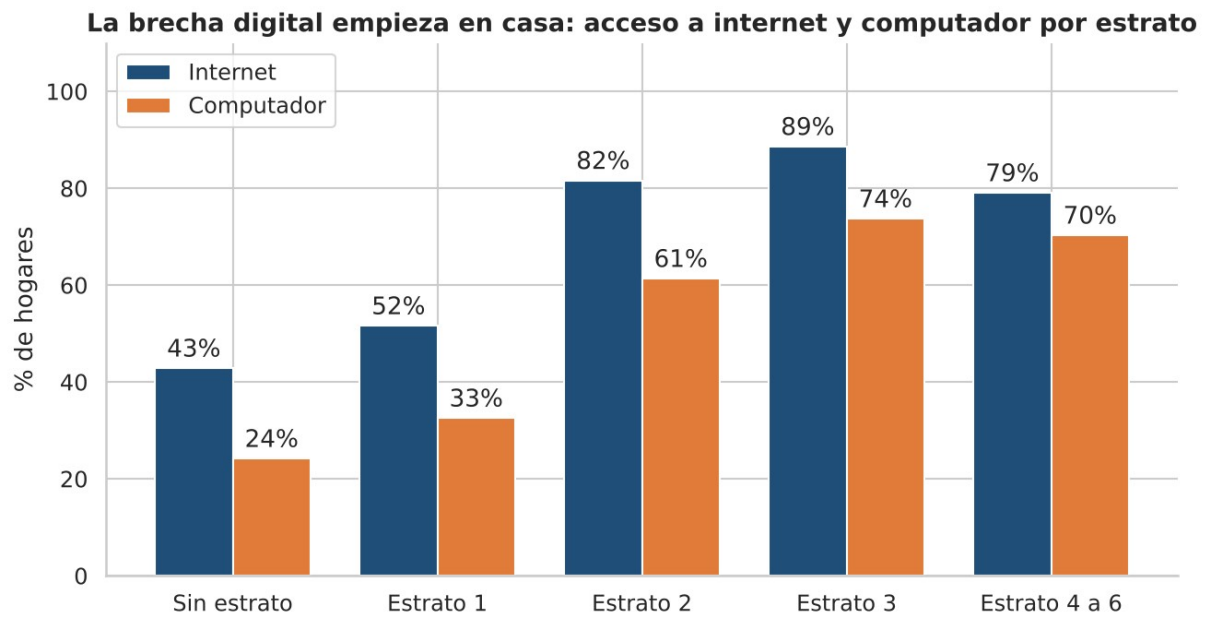
Zona urbana: +27

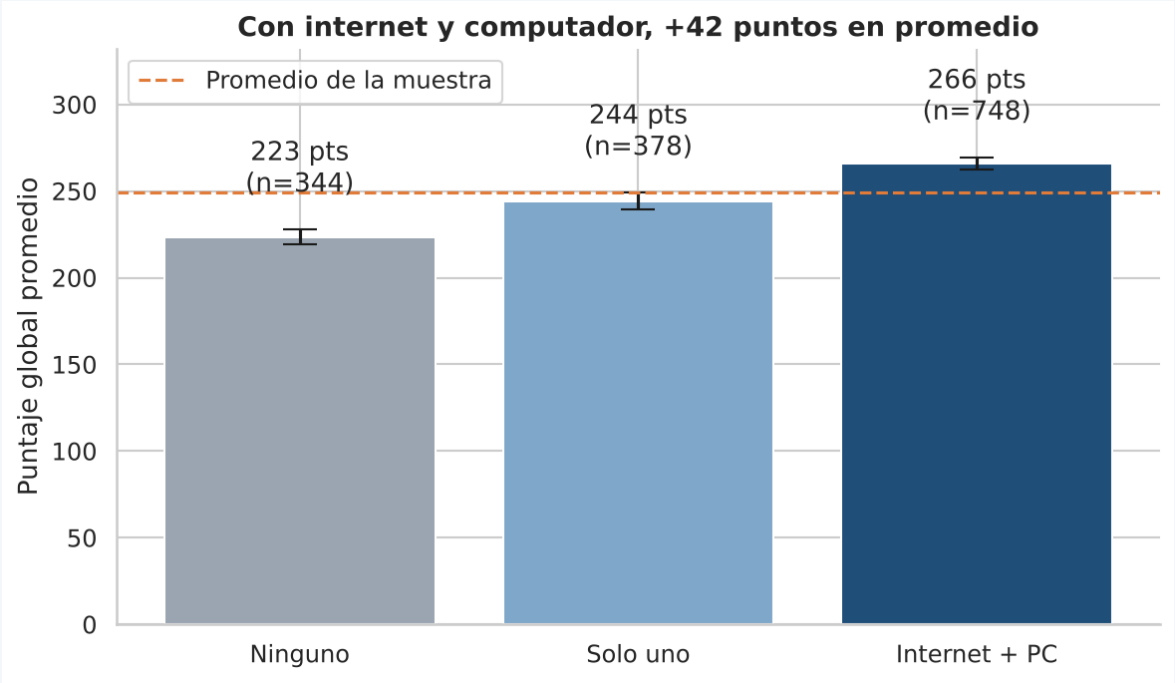
Prueba t (internet)

$p < 0{,}001$ · d de Cohen = 0,68 (efecto mediano-grande)

La brecha empieza en casa… y llega al examen

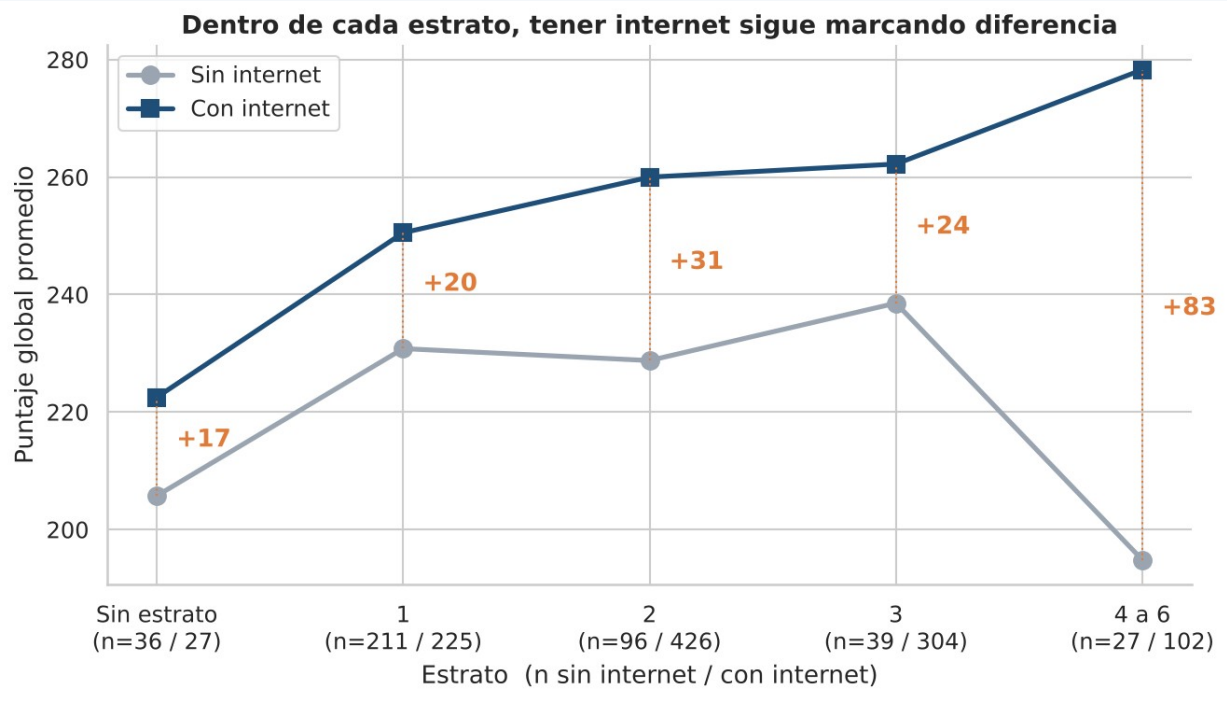
ETAPA 3

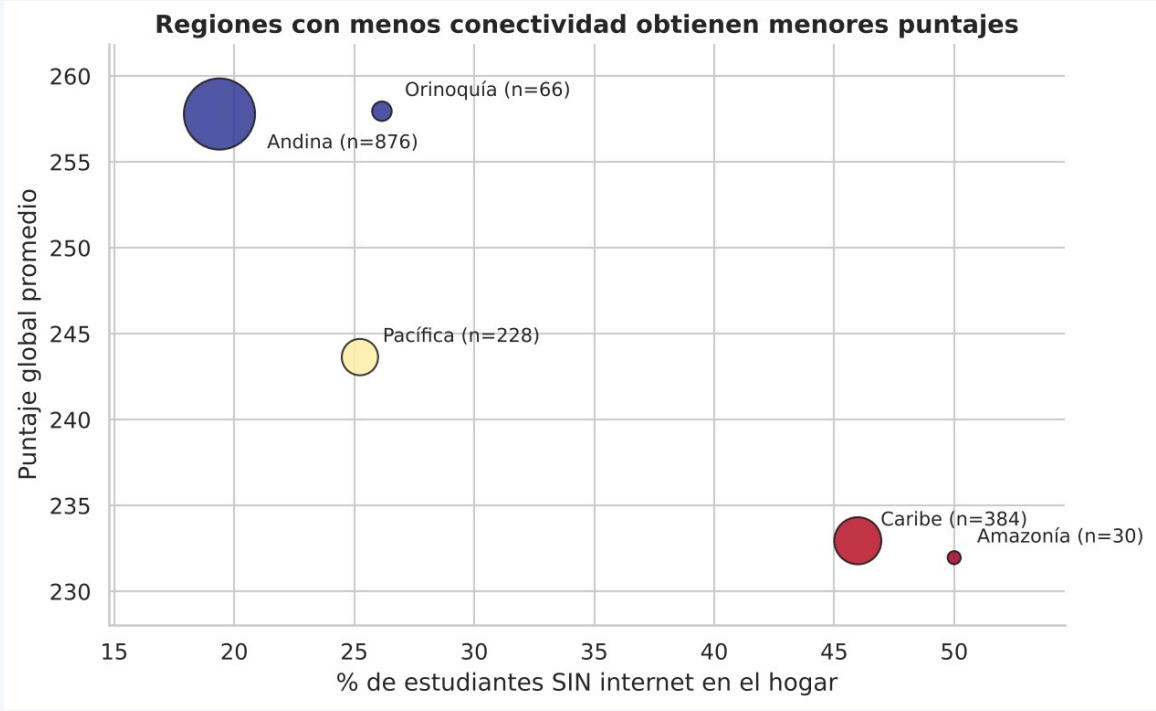




28 % de los estudiantes no tiene internet y 46 % no tiene computador. Con ambos recursos, el promedio sube 42 puntos.

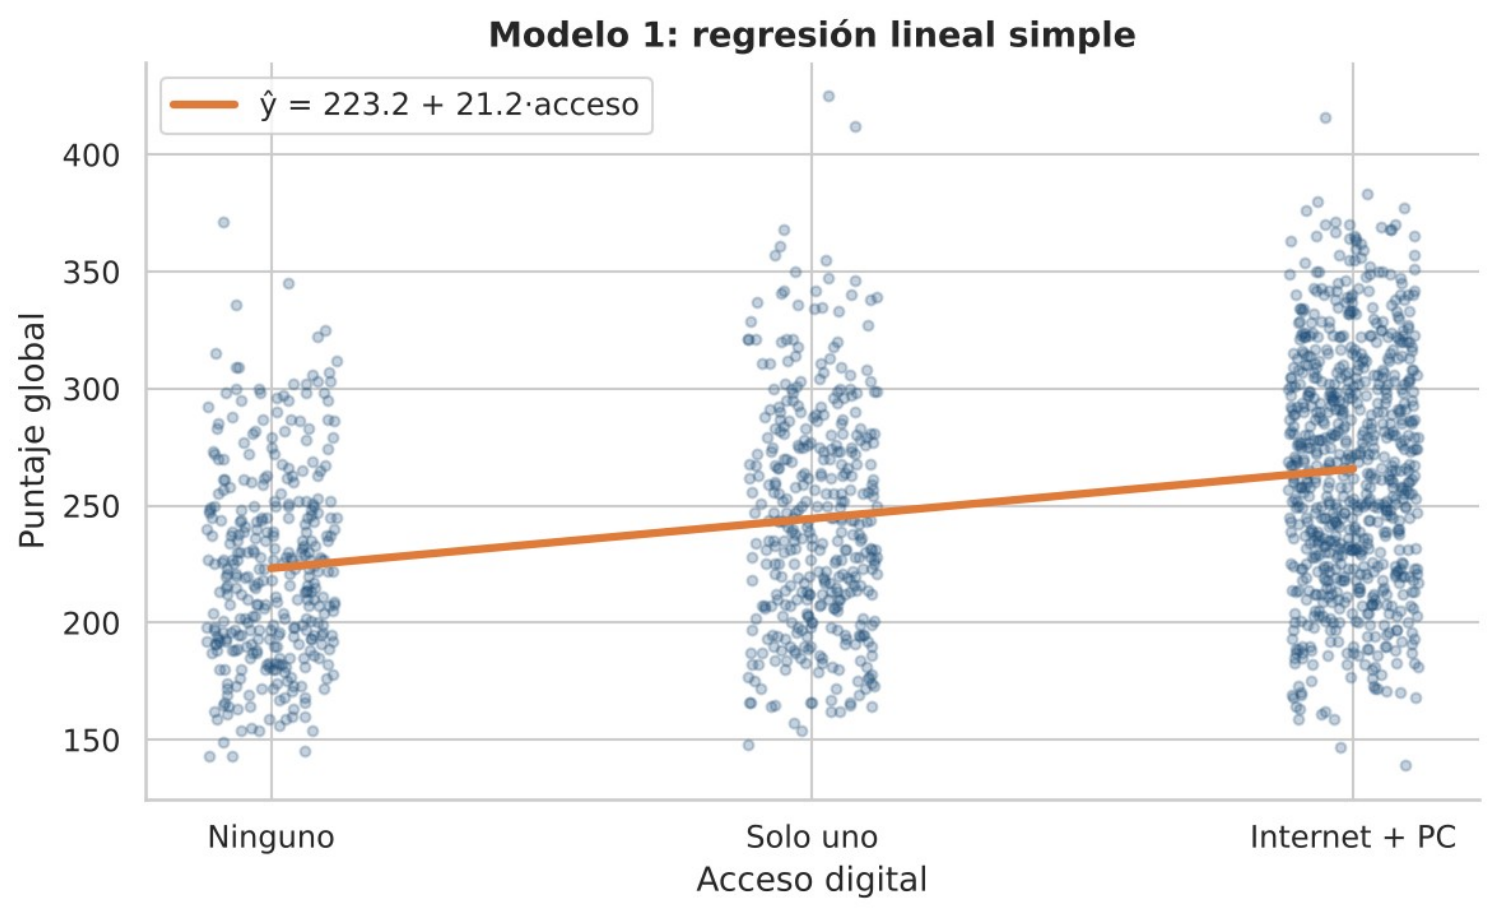
No es solo el estrato: también es territorio





Dentro de cada estrato, tener internet suma entre 17 y 31 puntos. Caribe y Amazonía: ~50 % sin internet y los puntajes más bajos.

Modelo 1 · Regresión lineal simple



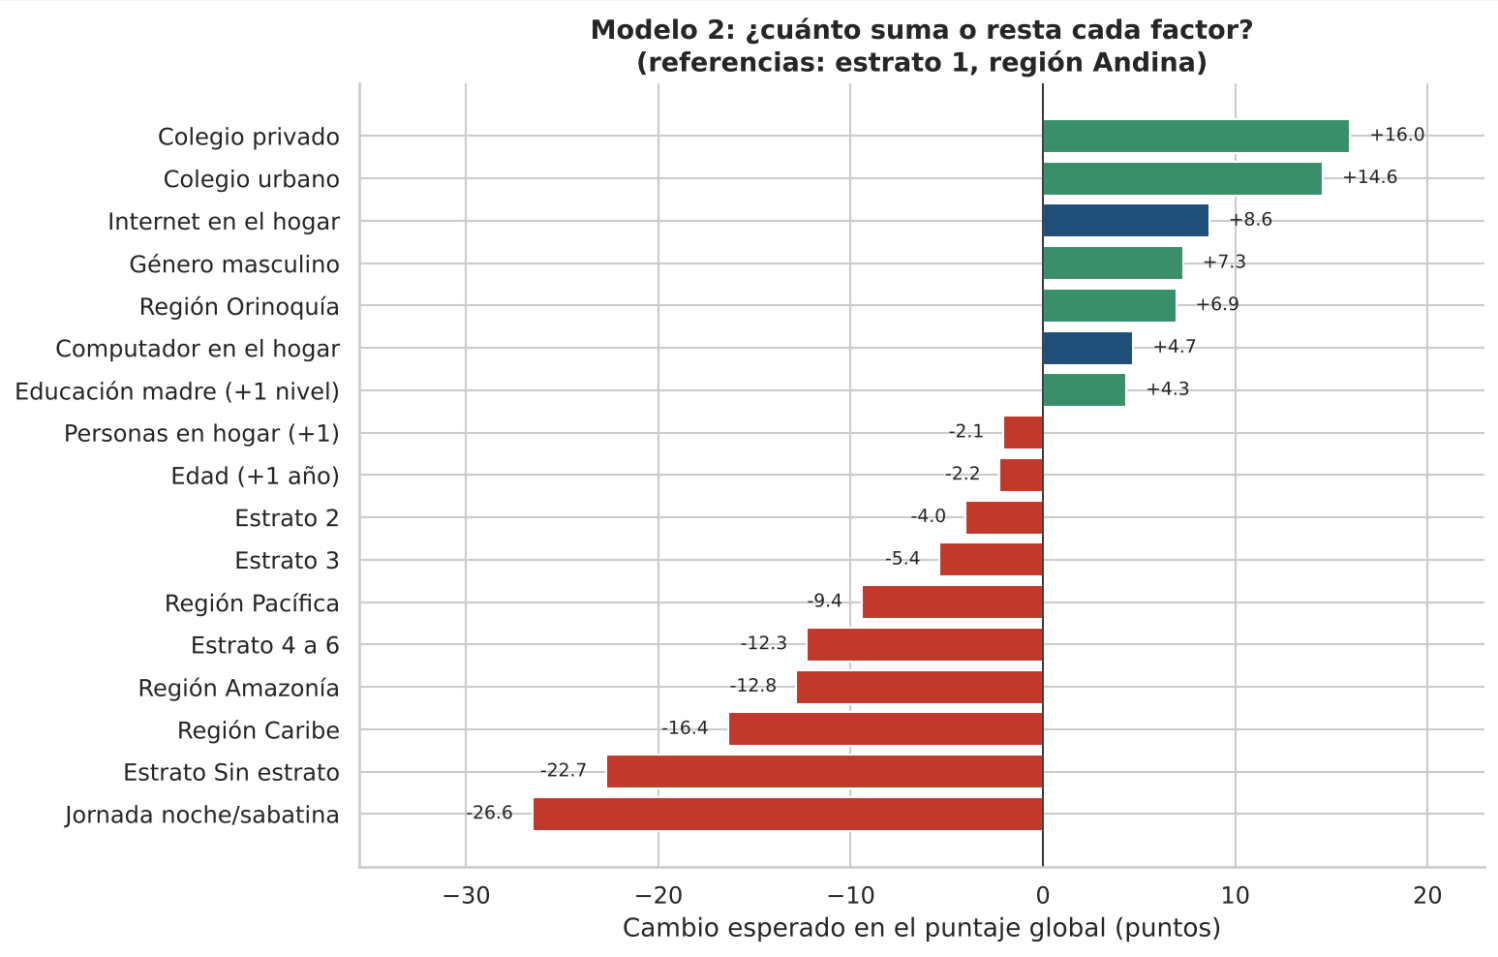
ŷ = 223,2 + 21,2 · acceso digital

- Sin internet ni PC: 223 puntos esperados.
- Cada recurso digital adicional: +21 puntos (IC 95 %: 18 a 24).
- R^2 = 0,12: una sola variable explica el 12 % de la variación.

Limitación

No controla estrato, colegio ni familia → necesitamos un modelo múltiple.

Modelo 2 · Regresión lineal múltiple



Evaluación (20 % de prueba)

R^2 = 0,24 · MAE = 36,7 pts (base: 42,6)

Validación cruzada: R^2 = 0,245 ± 0,02 → estable

Controlando todo lo demás

Internet: +10 pts (p = 0,002)

Computador: +8 pts (p = 0,004)

Educación madre: +4,7 por nivel

Colegio privado: +15 · Urbano: +11

Hallazgo

El estrato pierde peso: lo que importa es lo que el estrato permite tener.

Lo que nos cuentan los datos

1. Punto de partida

3 de cada 10 estudiantes presentan el Saber 11 sin internet en casa.

2. El conflicto

Obtienen 42 puntos menos que quienes tienen internet y PC.

3. ¿Solo el estrato?

No: aun comparando estudiantes similares, internet + PC suman ~18 puntos.

4. Desenlace

Es un factor que sí se puede intervenir con tecnología e inversión pública.

Asociación no es causalidad, pero la evidencia es consistente en tablas, pruebas de hipótesis y modelos.

Aplicación profesional · Ingeniería de Sistemas

Sistema de alerta temprana y priorización de conectividad educativa

ETL

Pipeline en Python que consulta la API de datos.gov.co y limpia los datos

›

Base de datos

Histórico por estudiante, colegio y municipio (PostgreSQL)

›

Modelo

Puntaje esperado según contexto, re-entrenado cada periodo

›

Dashboard

Mapa de municipios prioritarios para wifi, equipos y aulas digitales

›

Impacto

Comparar resultado real vs. esperado tras cada intervención

También aplicable en telecomunicaciones (zonas con demanda de conectividad) y en EdTech (contenidos offline para estudiantes con menos acceso).

Aprendizajes y próximos pasos

Lo que aprendimos

- Los datos públicos reales vienen “sucios”: la limpieza es la mitad del trabajo.
- Las estadísticas descriptivas y las pruebas de hipótesis convierten intuiciones en evidencia.
- Un modelo simple, bien evaluado e interpretado, comunica más que uno complejo.
- Una buena historia conecta datos, gráficos y decisiones.

Limitaciones

Datos observacionales · un solo periodo · variables autoreportadas · $R^2 \approx 0{,}25$

Próximos pasos

- Analizar 2019–2024 (efecto pandemia)
- Probar árboles / random forest
- Cruzar con cobertura de internet fijo del MinTIC por municipio